

Big Data (BDA501)

Bài tập Nhóm Cuối Kỳ (40%)

1. Mục tiêu

Học viên làm việc nhóm để triển khai thành công một pipeline xử lý Big Data sử dụng Hadoop hoặc Spark trên môi trường phân tán (cluster local hoặc cloud), thực hiện các bước xử lý dữ liệu từ thu thập, phân tích, đến trích xuất thông tin giá trị.

2. Yêu cầu bắt buộc

2.1 Về kỹ thuật

- Chọn một công cụ chính: Hadoop (MapReduce/Pig/Hive) hoặc Spark (RDD/DataFrame/MLlib)
- Xử lý một tập dữ liệu lớn ($\geq 500\text{MB}$): Chọn từ Kaggle, UCI hoặc từ open dataset.

Triển khai tối thiểu các bước sau:

1. Thu thập và nhập dữ liệu (dùng Sqoop, Flume, hoặc trực tiếp qua HDFS/Spark).
2. Xử lý dữ liệu thô: làm sạch, định dạng lại (dùng Pig, Hive hoặc Spark).
3. Phân tích dữ liệu: thống kê mô tả, lọc, tổng hợp.
4. Ứng dụng ML (nếu dùng Spark): áp dụng thuật toán đơn giản (k-means hoặc decision tree).
5. Triển khai hệ thống xử lý trên một cluster local (pseudo-distributed mode) hoặc cloud (khuyến khích dùng Leaner Lab của AWS để triển khai).

2.2 Về báo cáo và thuyết trình

Báo cáo nhóm gồm:

- Mô tả bài toán và mục tiêu xử lý dữ liệu
- Mô tả hệ thống triển khai (sơ đồ kiến trúc)
- Hướng dẫn cài đặt, công nghệ sử dụng
- Mã nguồn chính và kết quả phân tích
- Khó khăn và giải pháp nhóm đã xử lý

Trình bày (Presentation cuối kỳ):

- Tối đa 15 phút trình bày, 15 phút hỏi đáp
- Trình bày kết quả demo thực tế và mô hình kiến trúc

3. Một vài gợi ý đề tài (chỉ là gợi ý, không bắt buộc)

1. Trending YouTube Video Statistics

<https://www.kaggle.com/datasets/datasnaek/youtube-new>

Mô tả: Bộ dữ liệu gồm thông tin về các video đang thịnh hành trên YouTube theo quốc gia (tiêu đề, lượt xem, lượt thích, chủ đề,...).

Gợi ý triển khai:

- Sử dụng **Spark SQL** để phân tích xu hướng theo thời gian hoặc theo quốc gia.
- Xác định video có tốc độ lan truyền nhanh nhất.
- Dùng **Hive** để lưu trữ và truy vấn các bảng phân tích theo quốc gia.

2. License Plate Recognition Dataset

<https://www.kaggle.com/datasets/adilshamim8/license-plate-recognition>

Mô tả: Bộ dữ liệu gồm hình ảnh biển số xe và nhãn OCR tương ứng.

Gợi ý triển khai:

- Sử dụng **Spark + MLlib** cho bài toán phân loại ảnh hoặc huấn luyện mô hình nhận diện.
- Tiền xử lý ảnh bằng **PySpark** hoặc chuyển đổi thành thông tin text để xử lý thống kê.
- Sử dụng HDFS để lưu trữ tập ảnh lớn.

3. Credit Card Fraud Detection

<https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>

Mô tả: Bộ dữ liệu gồm các giao dịch thẻ tín dụng, được gán nhãn là gian lận hoặc không gian lận.

Gợi ý triển khai:

- Dùng **Spark MLlib** để huấn luyện mô hình phát hiện gian lận (decision tree, logistic regression).
- Sử dụng **MapReduce** hoặc **Spark DataFrame** để phân tích hành vi người dùng.
- Trực quan hóa tỷ lệ gian lận theo giờ/ngày.

4. Brain Tumor Dataset: Segmentation & Classification

<https://www.kaggle.com/datasets/indk214/brain-tumor-dataset-segmentation-and-classification>

Mô tả: Tập dữ liệu ảnh MRI chụp não, có nhãn về loại u (meningioma, glioma, pituitary).

Gợi ý triển khai:

- Dùng **Spark MLlib** để xây dựng mô hình phân loại hình ảnh.
- Tiền xử lý ảnh hàng loạt bằng **Spark RDD** hoặc DataFrame.
- Triển khai pipeline đọc ảnh từ HDFS, trích xuất đặc trưng, phân loại.

5. Student Performance

<https://www.kaggle.com/datasets/neuralsorcerer/student-performance>

Mô tả: Thông tin kết quả học tập, hành vi và hoàn cảnh của học sinh (giới tính, tình trạng gia đình, thời gian học, điểm thi...).

Gợi ý triển khai:

- Phân tích mối tương quan giữa điểm số và các yếu tố như thời gian học, tình trạng cha mẹ,... bằng **Hive** hoặc **Spark SQL**.

- Dự đoán sinh viên có nguy cơ rớt môn bằng **Spark MLlib**.
- Xử lý dữ liệu đầu vào bằng Pig hoặc MapReduce để tổng hợp dữ liệu.

4. Tiêu chí đánh giá (100 điểm – Final Assessment)

Tiêu chí	Trọng số
Độ chính xác, đúng kỹ thuật	30
Tính sáng tạo, giải quyết vấn đề	15
Mức độ hoàn chỉnh của sản phẩm	15
Kỹ năng trình bày	20
Mức độ hoàn chỉnh của report	20
Tổng	100